

សៀវភៅសង្ខេបមេរៀនសម្រាប់ប្រឡង

Data Analytics - Chapter 1 ដល់ Chapter 6

រៀបចំពីមេរៀនដែលបានធ្វើ៖ Python, Data Collection, Data Storage, Data Cleaning, Data Aggregation និង Grouping

គោលបំណង៖ សង្ខេប + ពន្យល់លម្អិតជាភាសាខ្មែរ ដើម្បីងាយរំលឹកមុនប្រឡង។

ផែនទីមេរៀនទាំងមូល

លំដាប់ការងាររបស់ Data Science អាចចងចាំជា៖

Data → Data Collection → Data Storage → Data Wrangling/Cleaning → Aggregation/Grouping → Analysis → Report

- Chapter 1៖ ស្គាល់ Data Science និងការប្រើ pandas លើ Iris dataset។
- Chapter 2៖ មូលដ្ឋាន Python សម្រាប់ Data Analytics។
- Chapter 3៖ ប្រភេទទិន្នន័យ ប្រភពទិន្នន័យ និងវិធីប្រមូលទិន្នន័យ។
- Chapter 4៖ ការក្លែងប្រែទិន្នន័យ Format ផ្សេងៗ និង Data Wrangling។
- Chapter 5៖ Data Cleaning - missing values, outliers, duplicates។
- Chapter 6៖ Aggregation និង Grouping ដោយប្រើ pandas groupby, agg, pivot_table។

ពាក្យគន្លឹះ៖ DataFrame = តារាង, Series = ជួរឈរ, row = ជួរដេក, column = ជួរឈរ, missing value = តម្លៃបាត់, duplicate = ទិន្នន័យស្អាត, outlier = តម្លៃខុសឆ្ងាយពីគេ។

Chapter 1: Introduction to Data Science

សង្ខេបខ្លី

- Data Science គឺជាការប្រើទិន្នន័យ ដើម្បីយល់បញ្ហា រកលំនាំ និងជួយសម្រេចចិត្ត។
- មេរៀនប្រើ Iris dataset ដែលមាន 150 rows និង 5 columns។
- ត្រូវចេះប្រើ pandas commands ដូចជា head(), shape, columns, info(), describe(), isnull().sum() និង value_counts()។

លម្អិតសម្រាប់រៀនប្រឡង

- df.head() បង្ហាញ 5 rows ដំបូង។
- df.shape បង្ហាញចំនួន rows និង columns។ ឧទាហរណ៍ Iris = (150, 5)។
- df.info() បង្ហាញ data type, non-null values និង memory usage។
- df.describe() បង្ហាញ count, mean, std, min, 25%, 50%, 75%, max សម្រាប់ numerical columns។
- value_counts() ប្រើរាប់ចំនួន category ដូចជា species នីមួយៗ។

Code ដែលគួរចងចាំ

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('https://raw.githubusercontent.com/mwaskom/seaborn-data/master/iris.csv')
print(df.head())
print(df.shape)
print(df.info())
print(df.describe())
print(df['species'].value_counts())
```

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- ចងចាំថា DataFrame គឺជាតារាង 2D និង Series គឺជាជួរឈរ 1D។
- សំណួរប្រឡងអាចសួរថា command មួយៗប្រើធ្វើអ្វី។

- Iris dataset មាន species 3 ប្រភេទ៖ setosa, versicolor, virginica។

Chapter 2: Python for Data Analytics

សង្ខេបខ្លី

- Python ងាយស្រួលរៀន មាន syntax អានងាយ និងមាន libraries ច្រើនសម្រាប់ Data Science។
- Python អាចប្រើសម្រាប់ data cleaning, transformation, model building, visualization និង deployment។
- ត្រូវចេះ data types, data structures, conditions, loops, functions, modules និង pandas data handling។

លម្អិតសម្រាប់រៀនប្រឡង

- Data types សំខាន់ៗ៖ int, float, str, bool។
- List គឺ ordered និង changeable; Tuple គឺ ordered ប៉ុន្តែ unchangeable។
- Set មិនរក្សាលំដាប់ និងមិនអនុញ្ញាត duplicates។
- Dictionary រក្សាទិន្នន័យជា key-value pairs។
- if/elif/else ប្រើសម្រេចលក្ខខណ្ឌ។ for loop និង while loop ប្រើធ្វើការដដែលៗ។
- Function គឺ block code ដែលអាចហៅប្រើឡើងវិញបាន។ Module គឺ library ឬ file ខាងក្រៅដែល import មកប្រើ។

ប្រៀបធៀប Data Structures

Structure	Ordered	Changeable	Duplicates	Example
List	Yes	Yes	Yes	[1,2,3]
Tuple	Yes	No	Yes	(1,2,3)
Set	No	Yes	No	{1,2,3}
Dict	Yes	Yes	No duplicate keys	{"name":"Alice"}

Code ដែលគួរចងចាំ

```
x = 10
if x > 5:
    print('Greater than 5')
else:
    print('5 or less')

for i in range(5):
    print(i)

def greet(name):
    return f'Hello, {name}'
```

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- ត្រូវចេះបែងចែក list, tuple, set, dict។
- ត្រូវចេះ syntax របស់ if statement, loop និង function។
- ត្រូវដឹងថា pandas និង numpy ជា libraries សំខាន់សម្រាប់ data analytics។

Chapter 3: Data Collection Methods

សង្ខេបខ្លី

- Data គឺជា raw information សម្រាប់ analysis និង decision-making។
- គុណភាពទិន្នន័យប៉ះពាល់ខ្លាំងដល់លទ្ធផល analysis។
- ត្រូវចែកប្រភេទ data: structured/unstructured, qualitative/quantitative, internal/external។

លម្អិតសម្រាប់រៀនប្រឡង

- Structured data មាន rows និង columns ដូចជា Excel, CSV, SQL។
- Unstructured data គ្មាន format ច្បាស់ ដូចជា emails, social media posts, images, audio, video។
- Qualitative data ជាទិន្នន័យពិតណាស់ មិនមែនលេខ ដូចជា reviews ឬ interview responses។
- Quantitative data ជាទិន្នន័យលេខ អាចវាស់ និងធ្វើ statistical analysis បាន ដូចជា age, height, income។
- Internal data កើតពីក្នុងអង្គការ ដូចជា sales reports; external data មកពីក្រៅ ដូចជា government open data។
- Data collection methods មាន surveys, web scraping, sensors/IoT, APIs និង logs/system files។

6 Dimensions of Data Quality

Dimension	អត្ថន័យ	របៀបពិនិត្យ
Accuracy	ត្រឹមត្រូវ និងពិត	Cross-check ជាមួយ source គួរឱ្យទុកចិត្ត
Completeness	មិនខ្វះតម្លៃ	រក NULL/missing values
Consistency	ស្មើគ្នា across sources	ប្រៀបធៀប dataset ផ្សេងៗ
Timeliness	ទាន់សម័យ	ពិនិត្យ timestamp/last update
Validity	ត្រឹមត្រូវតាម format/rules	validation rules
Uniqueness	មិនស្គម	check duplicate rows/IDs

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- ចងចាំឃ្លាន៖ Quality data = Quality insights។
- Bad data អាចបង្ក bias, incomplete analysis និង model results ខុស។
- មុន collect data ត្រូវ define goal និង identify data type/format។

Chapter 4: Data Storage, Formats & Wrangling

សង្ខេបខ្លី

- Data storage គឺកន្លែងរក្សាទុក digital information សម្រាប់យកមក process និង analyze ពេលក្រោយ។
- Choosing right storage ប៉ះពាល់ដល់ performance, scalability និង accessibility។
- Data wrangling គឺបម្លែង និងសម្អាត raw data ឱ្យអាចយកទៅ analyze បាន។

លម្អិតសម្រាប់រៀនប្រឡង

- Flat files ឧទាហរណ៍ CSV/TXT សាមញ្ញ និងងាយ share។
- Relational DBs ប្រើ SQL និងមាន structured schema ដូចជា MySQL/PostgreSQL។
- NoSQL DBs មាន flexible schema សមស្រប unstructured/real-time apps ដូចជា MongoDB/Firebase។
- Data Lakes អាចរក្សាទុក structured និង unstructured data ក្នុង scale ធំ។

- CSV ប្រើសម្រាប់ quick sharing; Excel ប្រើសម្រាប់ business reports; JSON ប្រើសម្រាប់ API/web data; SQL ប្រើសម្រាប់ structured database។
- Data wrangling រួមមាន loading, exploring, cleaning, transforming, filtering, merging, reshaping និង saving data។

Common Data Formats

Format	Type	Use Case	Python Tool
CSV	Tabular	General datasets	pd.read_csv()
Excel	Tabular	Reports/business data	pd.read_excel()
JSON	Semi-structured	APIs/web data	pd.read_json()
SQL	Structured	Database extraction	pd.read_sql_query()

Code ដែលគួរចងចាំ

```
df_csv = pd.read_csv('iris.csv')
df_excel = pd.read_excel('iris.xlsx')
df_json = pd.read_json('iris.json')

filtered = df[df['sepal_length'] > 6.0]
sorted_df = df.sort_values(by='petal_width', ascending=False)
```

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- សំណួរប្រឡងអាចសួរ when to use CSV, Excel, JSON, SQL។
- ចេះ filter data ដោយ condition និង sort data ដោយ column។
- ចងចាំថា DataFrame = table និង Series = single column។

Chapter 5: Data Cleaning & Preprocessing

សង្ខេបខ្លី

- Data cleaning គឺ process រក កែ ឬលុប inaccurate, incomplete, irrelevant data។
- បញ្ហាសំខាន់ៗ៖ missing values, outliers និង duplicates។
- Clean data ជួយឱ្យ analysis ត្រឹមត្រូវ និង machine learning model ប្រសើរ។

លម្អិតសម្រាប់រៀនប្រឡង

- Missing data អាចកើតពី user input error, sensor malfunction ឬ merging datasets។
- MCAR = missing completely at random; MAR = depends on observed data; MNAR = depends on missing value itself។
- dropna() លុប rows/columns ដែលមាន missing values។ ប្រើពេល missing តិច។
- fillna() បំពេញ missing values ដោយ mean, median, mode ឬ constant value។
- Forward fill/backward fill ប្រើសម្រាប់ time series data។
- Outlier គឺ data point ខុសឆ្ងាយពីតម្លៃផ្សេងៗ។ អាចរកដោយ Z-score ឬ IQR។
- Duplicate គឺ row/record ដែលស្ទើរដូចគ្នា។ អាចរកដោយ duplicated() និងលុបដោយ drop_duplicates()។

Missing Data Strategy

Method	ពេលប្រើ	Caution
--------	---------	---------

Drop	Missing តិច	អាចបាត់ data សំខាន់
Simple Fill	Numeric/categorical columns	អាចកាត់បន្ថយ variability
Ffill/Bfill	Time series	សន្មត់ថា trend បន្ត
Conditional Fill	Missing depends on other variables	ត្រូវការ logic ច្រើន

Code ដែលគួរចងចាំ

```
print(df.isnull().sum())
df_clean = df.dropna()
df['age'].fillna(df['age'].mean(), inplace=True)
df_cleaned = df.drop_duplicates()

Q1 = df['sepal_length'].quantile(0.25)
Q3 = df['sepal_length'].quantile(0.75)
IQR = Q3 - Q1
outliers = df[(df['sepal_length'] < Q1 - 1.5*IQR) | (df['sepal_length'] > Q3 + 1.5*IQR)]
```

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- កុំលុប outlier ដោយមិនពិនិត្យ ព្រោះវាអាចជា rare event ឬ fraud។
- Mean/median ប្រើសម្រាប់ numerical data; mode ប្រើសម្រាប់ categorical data។
- Always check missing values early with isnull().sum()។

Chapter 6: Data Aggregation & Grouping

សង្ខេបខ្លី

- Data aggregation គឺសង្ខេប និងបញ្ចូល data ដើម្បីរក insight ដោយប្រើ mean, sum, count, min, max ជាដើម។
- Grouping បំបែក data ជាក្រុមដោយ categorical column ដូចជា species។
- Pandas tools សំខាន់ៗ៖ groupby(), mean(), size(), agg(), pivot_table()។

លម្អិតសម្រាប់រៀនប្រឡង

- groupby() មានគំនិត split → apply → combine។
- grouped.mean() គណនាមធ្យមតាម group។
- grouped.size() រាប់ចំនួន rows ក្នុង group។
- agg() អនុញ្ញាតឱ្យប្រើ aggregation functions ច្រើនក្នុងពេលតែមួយ។
- Grouping by multiple columns ប្រើពេលចង់ analyze subcategories ឧទាហរណ៍ species និង petal_size។
- pivot_table() ប្រើ reshape data ដើម្បីបង្កើត summary table សម្រាប់ dashboard ឬ comparison។

Aggregation Functions

Function	អត្ថន័យ
mean()	រកមធ្យមភាគ
sum()	បូកសរុប
count()	រាប់ non-null values
size()	រាប់ rows ក្នុង group
min()/max()	តម្លៃតូចបំផុត/ធំបំផុត
std()	standard deviation

agg()	ប្រើ functions ច្រើន
pivot_table()	បង្កើត summary table

Code ដែលគួរចងចាំ

```
grouped = df.groupby('species')
print(grouped.mean(numeric_only=True))
print(grouped.size())

print(grouped.agg({
    'sepal_length': 'mean',
    'sepal_width': 'max',
    'petal_width': 'std'
}))

df['petal_size'] = ['large' if x > 4.5 else 'small' for x in df['petal_length']]
print(df.groupby(['species', 'petal_size']).size())

pivot = df.pivot_table(values='sepal_length', index='species', aggfunc='mean')
```

ចំណុចដែលគួរចងចាំសម្រាប់ប្រឡង

- ប្រសិនបើសំណួរសួរ “average by category” ត្រូវគិតពី groupby()។
- ប្រសិនបើសំណួរសួរ summary table ឬ rows/columns comparison ត្រូវគិតពី pivot_table()។
- សម្រាប់ Titanic challenge ត្រូវចេះ group by passenger class, gender, survived និង fare។

Cheat Sheet សម្រាប់មុនចូលប្រឡង

Commands pandas ដែលគួរចងចាំ

Command	ន័យ/ប្រើធ្វើអ្វី
df.head()	បង្ហាញ rows ដំបូង
df.shape	បង្ហាញ rows និង columns
df.columns	បង្ហាញឈ្មោះ columns
df.info()	បង្ហាញ dtype និង non-null values
df.describe()	summary statistics
df.isnull().sum()	រាប់ missing values
df.dropna()	លុប missing rows/columns
df.fillna()	បំពេញ missing values
df.duplicated().sum()	រាប់ duplicates
df.drop_duplicates()	លុប duplicates
df.groupby()	បែង data ជាក្រុម
df.agg()	aggregation ច្រើន
df.pivot_table()	summary table/reshape
df.sort_values()	តម្រៀប rows
df.value_counts()	រាប់ categories

សំណួរហាត់សាកល្បង

1. Structured data និង unstructured data ខុសគ្នាយ៉ាងដូចម្តេច?
2. Qualitative data និង quantitative data ខុសគ្នាយ៉ាងដូចម្តេច?
3. តើ 6 dimensions of data quality មានអ្វីខ្លះ?
4. តើ df.info() និង df.describe() បង្ហាញអ្វី?
5. តើ dropna() និង fillna() ខុសគ្នាយ៉ាងដូចម្តេច?
6. តើ outlier ជាអ្វី? រកដោយវិធីណាខ្លះ?
7. តើ duplicate row ជាអ្វី? រក និងលុបដោយ command អ្វី?
8. តើ groupby() ប្រើពេលណា?
9. តើ agg() ប្រើធ្វើអ្វី?
10. តើ pivot_table() មានប្រយោជន៍អ្វី?