

Data Analytics Exam Review - Chapters 1-6

ឯកសារនេះមានចម្លើយខ្លី + ពន្យល់លម្អិតជាភាសាខ្មែរ និង English keywords សម្រាប់រៀនប្រឡង។

Cheat Sheet ខ្លីមុនចូលប្រឡង

Topic	ចំណុចត្រូវចាំ
Structured data	មាន rows និង columns ដូចជា Excel, CSV, SQL
Unstructured data	គ្មាន format ច្បាស់ ដូចជា email, image, video
Qualitative data	ទិន្នន័យពិតណាស់ មិនមែនលេខ
Quantitative data	ទិន្នន័យជាលេខ អាចវាស់វែងបាន
Data cleaning	ដោះស្រាយ missing values, outliers, duplicates
Aggregation	សង្ខេប data ដោយ mean, sum, count, min, max

1. Structured data និង Unstructured data ខុសគ្នាយ៉ាងដូចម្តេច?

Structured data គឺទិន្នន័យដែលមានរចនាសម្ព័ន្ធច្បាស់ មាន rows និង columns ដូចជា Excel, CSV, SQL។

Unstructured data គឺទិន្នន័យដែលគ្មាន format ច្បាស់ ដូចជា email, image, video, audio និង social media post។

ចម្លើយខ្លី៖ **Structured** = មានតារាង។ **Unstructured** = គ្មានទម្រង់ច្បាស់។

2. Qualitative data និង Quantitative data ខុសគ្នាយ៉ាងដូចម្តេច?

Qualitative data គឺទិន្នន័យពិតណាស់ មិនមែនលេខ ដូចជា review, opinion, interview response។ Quantitative

data គឺទិន្នន័យជាលេខ អាចវាស់វែង និងធ្វើ statistical analysis បាន ដូចជា age, height, income។

ចម្លើយខ្លី៖ **Qualitative** = ពិតណាស់។ **Quantitative** = ជាលេខ។

3. តើ 6 dimensions of data quality មានអ្វីខ្លះ?

6 dimensions រួមមាន Accuracy, Completeness, Consistency, Timeliness, Validity និង Uniqueness។

Accuracy មានន័យថាទិន្នន័យត្រឹមត្រូវ។ Completeness មានន័យថាទិន្នន័យមិនខ្វះ។ Consistency មានន័យថាទិន្នន័យស្មើគ្នា across sources។ Timeliness មានន័យថាទិន្នន័យសម័យ។ Validity មានន័យថាត្រឹមត្រូវតាម format/rules។ Uniqueness មានន័យថាមិនមាន duplicate data។

ចងចាំ៖ **Accurate, Complete, Consistent, Timely, Valid, Unique.**

4. តើ df.info() និង df.describe() បង្ហាញអ្វី?

df.info() បង្ហាញ column names, data type, non-null values និង memory usage។ df.describe() បង្ហាញ summary statistics សម្រាប់ numerical columns ដូចជា count, mean, std, min, 25%, 50%, 75%, max។

Code:

```
df.info()
df.describe()
```

5. តើ dropna() និង fillna() ខុសគ្នាយ៉ាងដូចម្តេច?

សម្រាប់រំលឹកមុនប្រឡង

dropna() ប្រើសម្រាប់លុប rows ឬ columns ដែលមាន missing values។ fillna() ប្រើសម្រាប់បំពេញ missing values ដោយ mean, median, mode ឬ constant value។

ចម្លើយខ្លី៖ **dropna()** = លុបតម្លៃបាត់។ **fillna()** = បំពេញតម្លៃបាត់។

```
df_clean = df.dropna()
df['age'].fillna(df['age'].mean(), inplace=True)
```

6. តើ **Outlier** ជាអ្វី? រកដោយវិធីណាខ្លះ?

Outlier គឺ data point ដែលខុសឆ្ងាយពីតម្លៃផ្សេងៗក្នុង dataset។ ឧទាហរណ៍ age ភាគច្រើន 20-60 ប៉ុន្តែមានតម្លៃ 999។ វិធីរក outlier មាន Z-score និង IQR method។

ចងចាំ៖ កុំលុប **outlier** ដោយមិនពិនិត្យ ព្រោះវាអាចជា **rare event** ឬ **fraud**។

```
Q1 = df['sepal_length'].quantile(0.25)
Q3 = df['sepal_length'].quantile(0.75)
IQR = Q3 - Q1
outliers = df[(df['sepal_length'] < Q1 - 1.5*IQR) | (df['sepal_length'] > Q3 + 1.5*IQR)]
```

7. តើ **Duplicate row** ជាអ្វី? រក និងលុបដោយ **command** អ្វី?

Duplicate row គឺ row ឬ record ដែលស្អាត ឬកើតឡើងច្រើនដងក្នុង dataset។ រកដោយ df.duplicated().sum() ឬ df[df.duplicated()]។ លុបដោយ df.drop_duplicates()។

Code:

```
df.duplicated().sum()
df[df.duplicated()]
df.drop_duplicates()
```

8. តើ **groupby()** ប្រើពេលណា?

groupby() ប្រើពេលយើងចង់បែងចែក data ជាក្រុមតាម category column។ ឧទាហរណ៍ ចង់រក average sepal length តាម species។ ប្រសិនបើសំណួរមានពាក្យ average by category ឬ count by group ត្រូវគិតពី groupby()។

Code:

```
df.groupby('species')['sepal_length'].mean()
```

9. តើ **agg()** ប្រើធ្វើអ្វី?

agg() ប្រើសម្រាប់ apply aggregation functions ច្រើនក្នុងពេលតែមួយ ដូចជា mean, max, min, std, count។ វាផ្តល់ summary ច្រើនលើ grouped data។

Code:

```
df.groupby('species').agg({
    'sepal_length': 'mean',
    'sepal_width': 'max',
    'petal_width': 'std'
})
```

10. តើ **pivot_table()** មានប្រយោជន៍អ្វី?

`pivot_table()` ប្រើសម្រាប់ summary table និង reshape data ដើម្បីងាយប្រៀបធៀប rows/columns។ វាសមស្របសម្រាប់ dashboard ឬ comparison table។

ចម្លើយខ្លី៖ **`pivot_table()`** ប្រើសម្រាប់សង្ខេបទិន្នន័យជា **table** ងាយមើល និងប្រៀបធៀប។

```
pivot = df.pivot_table(values='sepal_length', index='species', aggfunc='mean')
```

Quick Memory Tips

- 1) បើសំណួរមាន missing values គិតពី `isnull()`, `dropna()`, `fillna()`។
- 2) បើសំណួរមាន duplicate គិតពី `duplicated()` និង `drop_duplicates()`។
- 3) បើសំណួរមាន average/count by group គិតពី `groupby()`។
- 4) បើសំណួរមាន summary table ឬ comparison table គិតពី `pivot_table()`។